

HealthSearch — Busca Híbrida BM25 + Semântica (RRF)

UNIPÊ — Centro Universitário de João Pessoa · Tendências em Ciência da Computação · Laboratório Prático 05
Prof. Me. Ricardo Roberto de Lima · Equipe: [Integrante 1] · [Integrante 2] · [Integrante 3]

1. Problema


Médicos que buscam "infarto" não encontram diretrizes escritas como "síndrome coronariana" (falha do léxico), e buscas por códigos como CÓD-ECG-12D se diluem na busca vetorial (falha do semântico). O HealthSearch executa os dois motores em paralelo e os funde com Reciprocal Rank Fusion.

2. Arquitetura (healthsearch_app.py)

- **Fase 1 — Pré-processamento:** minúsculas, remoção de acentos e de caracteres especiais (preservando hífen, para "CÓD-ECG-12D" virar um único token "cod-ecg-12d") e remoção de stopwords em português. Título e conteúdo de cada diretriz são indexados juntos.
- **Fase 2 — BM25:** *rank_bm25.BM25Okapi* recriado a cada ajuste dos sliders k_1 (0–3, padrão 1,2) e b (0–1, padrão 0,75). Só entram no ranking léxico documentos com score > 0. Um expander mostra $f(t,D)$, $|D|$, avgdl , IDF e a contribuição de cada termo.
- **Fase 3 — Semântico:** embeddings do *intfloat/multilingual-e5-small* (com os prefixos "query:" e "passage:" que o modelo exige), normalizados, então o produto escalar é o cosseno. O modelo e os embeddings do corpus ficam em cache. Dois modelos MiniLM continuam disponíveis para comparação.
- **Fase 4 — RRF:** $\text{Score} = \alpha \cdot 1/(k + \text{Rank_BM25}) + (1 - \alpha) \cdot 1/(k + \text{Rank_Sem})$, com α na sidebar e $k = 60$. Documento ausente de uma lista não recebe a parcela dela. A tabela mostra as duas parcelas separadas.
- **Interface:** abas Léxico, Semântico, Híbrido RRF e Matriz Comparativa, com métricas de Top-1 e latência de cada motor e seis consultas de teste prontas.
- **Bônus — Cross-Encoder:** checkbox que reordena o Top-3 do RRF com um Cross-Encoder e mostra posição antiga, nova posição, variação e nota. O padrão é o *mmarco-mMiniLMv2* (multilíngue); o *ms-marco-MiniLM-L-6-v2* sugerido no enunciado fica como opção, com aviso de que foi treinado em inglês.

3. Comparação de ranks ($k_1 = 1,2 \cdot b = 0,75 \cdot \alpha = 0,5 \cdot k = 60$)

Barra mais alta = posição melhor; barra zerada = o motor não recuperou o documento.



Consulta	Top-1 BM25	Top-1 Semântico	Top-1 Híbrido
ataque cardíaco	nenhum	Doc 2	Doc 2
CÓD-ECG-12D	Doc 6	Doc 1	Doc 1
exame CÓD-ECG-12D para infarto	Doc 2	Doc 6	Doc 6

- **"ataque cardíaco":** nenhuma palavra em comum com o corpus, e o BM25 devolve vazio. O semântico acha a diretriz de infarto (Doc 2) e o RRF herda esse resultado.
- **"CÓD-ECG-12D":** o BM25 recupera exatamente os dois documentos com o código (Doc 1 e Doc 6) e ignora o resto.
- **"exame CÓD-ECG-12D para infarto":** o BM25 põe o Doc 2 em 1º por causa de "infarto", o termo mais raro. O RRF sobe o Doc 6, que aparece bem colocado nas duas listas: é a fusão premiando o consenso entre os motores.

4. Divisão de tarefas

Integrante	Responsabilidade
[Integrante 1]	Pré-processamento e motor BM25 com sliders (Fases 1 e 2)
[Integrante 2]	Motor semântico, escolha do modelo e Cross-Encoder (Fase 3 e bônus)
[Integrante 3]	Fusão RRF, abas comparativas e relatório (Fase 4)

Execução: `pip install -r requirements.txt` e `streamlit run healthsearch_app.py` (a primeira execução baixa os modelos do Hugging Face).